Mašinsko učenje: Projekat

Matej Vučković 2025/3040

Februar 2026

Pregled problema

Kao tema za ovaj problem odabrana je detekcija i klasifikacija aritmija iz ECG snimaka. Detekcija se zapravo odnosi na binarni problem klasifikacije između ECG snimka zdravog pulsa srca i aritmije. Klasifikacija aritmija se odnosi prepoznavanje kom tipu aritmija ona pripada, sa mogućnošću da taj tip bude i nedefinisan tj. "ostalo". Važno je naglasiti da skup podataka koji je korišćen ne predstavlja vremenske sekvence već veštački konstruisan skup osobina (eng. *feature engineering*) koje su različitim, uglavnom statističkim, metodama izračunate. Dakle, originalne vremenske serije se nalaze u MIT-BIH bazi, dok se podaci korišćeni za projekat nalaze na sledećem keggle linku.

Sam skup se sastoji od oko 500 različitih primeraka i 279 različitih osobina koje su na raspolaganju. Kako je broj prediktora prevelik, njihov prikaz je dat na kraju izveštaja u sekciji Dodatak. S obzirom da postoji izuzetno veliki broj različitih tipova aritmija raspodela podataka po klasama je očekivano ne balansirana (Slika 1). Najveći broj primeraka pripada upravo klasi 1 odnosno normalnim ECG snimcima. Klasa 16 odgovara nedefinisanom tipu aritmije. Detaljan pregled značenja svih klasa je dat u Tabeli 1. Kada se posmatra samo slučaj detekcije aritimije tada su klase mnogo bolje balansirane (Slika 2). Sada 1 označava postojanje aritmije dok je 0 normalni ECG snimak.

Klasa	**Naziv**
1	Normal
2	Ischemic changes (Coronary Artery Disease)
3	Old Anterior Myocardial Infarction
4	Old Inferior Myocardial Infarction
5	Sinus tachycardy
6	Sinus bradycardy
7	Ventricular Premature Contraction (PVC)
8	Supraventricular Premature Contraction
9	Left bundle branch block
10	Right bundle branch block
11	1. degree AtrioVentricular block
12	2. degree AV block
13	3. degree AV block
14	Left ventricule hypertrophy
15	Atrial Fibrillation or Flutter
16	Others

Tabela 1: Nazivi klasa

Podaci nisu kompletni zbog čega je bilo neophodno da se određene osobine uklone ili određeni redovi veštački dopune. U Tabeli 2 su prikazani odgovarajući procenti nedostajućih podataka. Na osnovu procenata osobine J i P su potpuno uklonjene, T je veštački popunjeno srednjom verdnošću a redovi sa nedostajućim Q ili heart_rate su uklonjeni. Dodatno, primećeno je da postoji oko 30 osobina

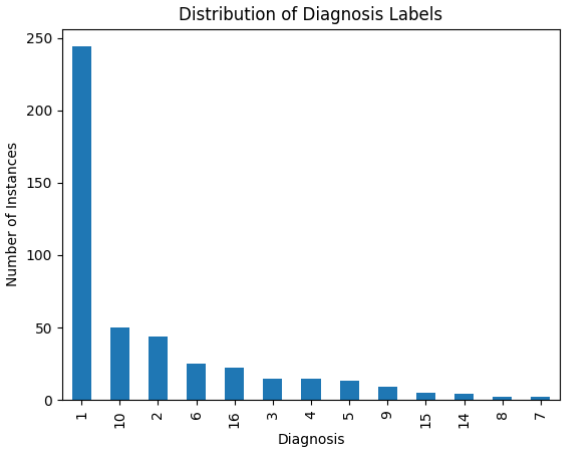

Slika 1: Raspodela broja primeraka po klasama

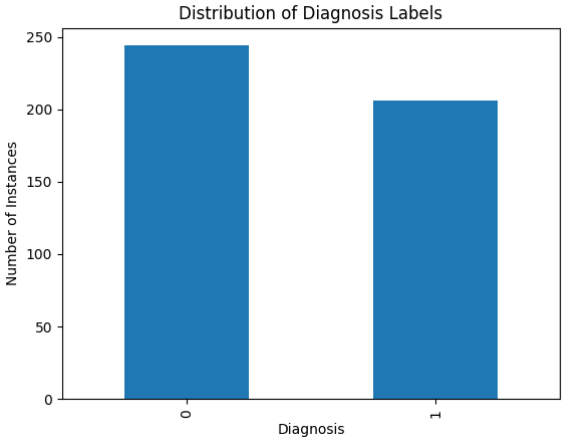

Slika 2: Raspodela broja primeraka za detekciju aritmija

koje su potpuno konstantne za ceo obučavajući skup (var = 0) pa su samim tim potpuno neinformativne i uklonjene. U sam proces obučavanja je ušlo tačno 250 osobina.

Osobina	**Procenat nedostajućih**
J	83.185841
P	4.867257
T	1.769912
QRST	0.221239
heart_rate	0.221239

Tabela 2: Pregled podataka koji nedostaju

1 Detekcija Aritmija

Prvo će u potpunosti biti ispitan problem binarne klasifikacije jer je on jednostavniji i očekuje se da će rezultati ovog problema predstaljati maksimalni mogući rezultat na problemu potpune klasifikacije. Iskorišćeno je više tipova klasifikatora i njihovih ansamblova kako bi se našao optimalni model. Analize su date zasebno po podsekcijama.

1.1 Logistička Regresija

Za trening je odabrana L2 regularizacija koja podešava hiperparametrom $C = 1/\lambda$. Ogroman broj osobina nužno iziskuje da odaberemo samo one najinformativnije kako bi smo uprostili problem i kako bi naš model mogao što bolje da generalizuje. Korišćena je ANOVA-F metrika za rangiranje prediktora a hiperparametar k definiše broj najbolje rangiranih koje zadržavamo u treningu i modelu. Pretraga hiperparametara se radi poređenjem vrednosti Unakrsne Validacije sa 5 grupa. Rezultat takve pretrage je prikazan na Slici 3. Vidi se da prevelik broj parametara svakako otežava obučavanje modela i da je okvirno najbolje koristiti prvih 150 parametara. Takođe, regularizacija je neophodna jer njenim slabljenjem (povećanje C) dolazi do urušavanje performansi i optimalna vrednost se nalazi u rasponu $10^{-1.5}$ i $10^{-0.5}$. Najveća dostignuta preciznost je 0.8 sa zadovoljavajuće malom varijansom. Detaljnom pretragom na užem prostoru hiperparametara, dobijena je preciznost 0.806 za $C^* = 0.01$ i $k^* = 130$. Regularicija je dakle izuzetno jaka što je verovatno posledica velike dimenzionalnosti prostora. Generisana je matrica konfuzije za trening skup, Slika 4, a u Tabeli 3 su date standardne metrike za performans modela na test skupu.

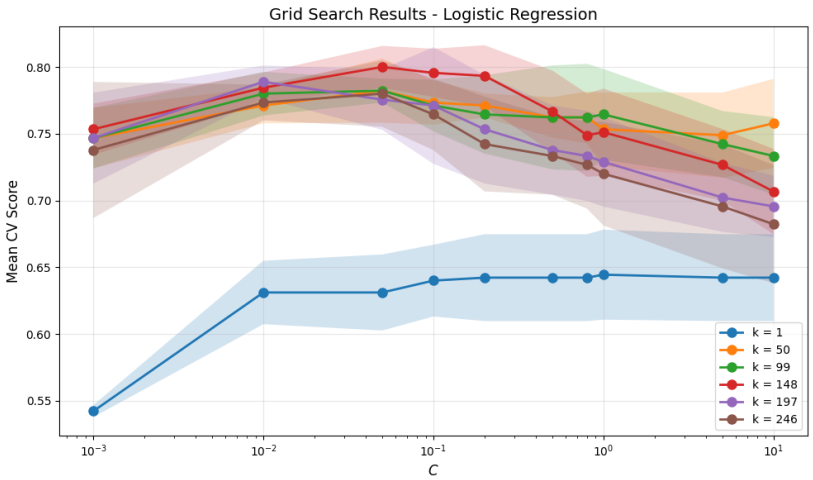

Slika 3: Pretraga za najbolji model u zavisnosti od broja atributa (k) i regularizacije (C)

Tačnost	0.7667
Precision	0.8000
Recall	0.6667
F1	0.7273

Tabela 3: Rezultati testiranja modela sa optimalnim hiperparametrima

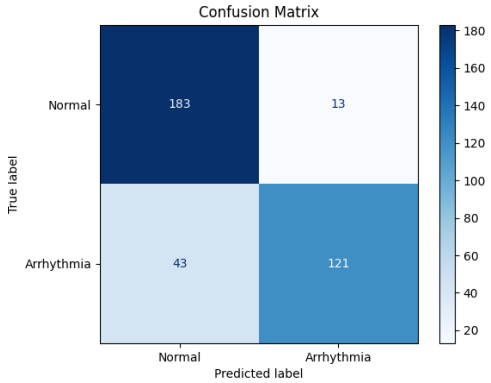

Slika 4: Matrica konfuzije za trening skup nakon obučavanja sa $C^* = 0.01$ i $k^* = 130$

1.2 Naivni Bayes

Radi kompletnosti odabrano je da se koristi i Naivni Bayes-ov klasifikator koji je potpuno statistički model i njegov performans jedino zavisi od broja prediktora koji su uvršćeni tj. k. Prevelik broj bi doveo do nepotrebnog usložnjavanja i samim tim pada performansi modela. Na Slici 5 se upravo vidi ova zavisnost. Kao optimalan broj odabran je $k^* = 67$ i model je tako i testiran (Tabela 4). Konfuziona matrica za obučavajući skup je prikazana na Slici 6.

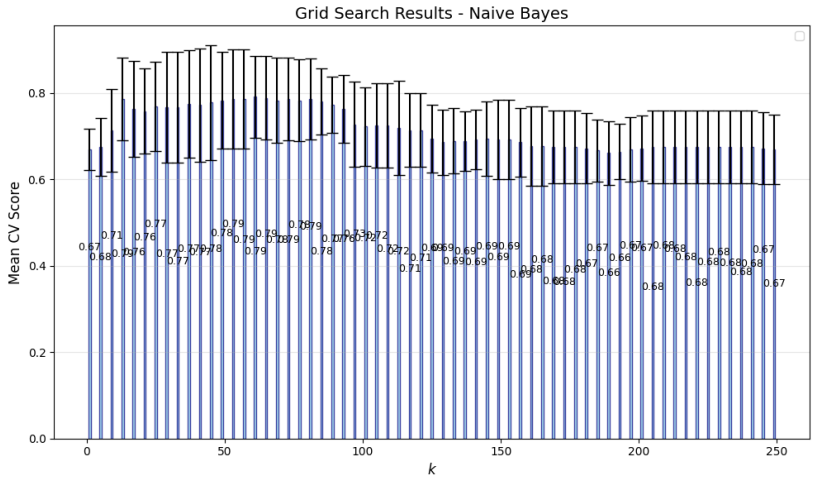

Slika 5: Pretraga za najbolji model u zavisnosti od broja prediktora (k)

Tačnost	0.7556
Precision	0.7941
Recall	0.6429
F1	0.7105

Tabela 4: Rezultati testiranja modela sa k^* prediktora

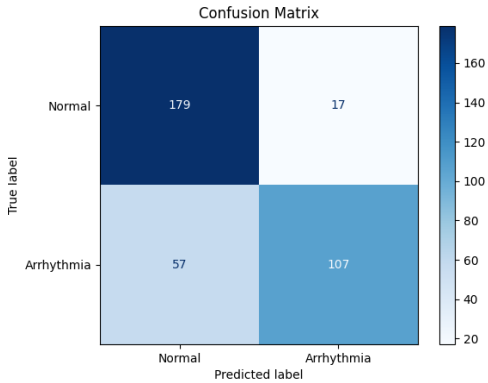

Slika 6: Matrica konfuzije za trening skup nakon obučavanja sa $k^* = 67$

1.3 Metoda nosećih vektora (SVM)

Kao poslednji "jednostavni" model odabran je SVM. Pretporstavljeno je da broj potrebnih prediktora je u sličnom okviru kao za logističku regresiju zbpg čega je k unapred fiksirano na 130. Ono što je moguće varirati kod ovog modela je tip kernela. Pored tipa, regularizacija se ponovo određuje inverznim koeficijentom C. Za određene kernele moguće je podesiti i njihovo ponašanje i to sa γ za gausov i sigmoidni tip, dok se za polinomijalni podešava maksimalni stepen polinoma. Na Slikama 7, 8 i 9 se nalaze mape pretrage za Gausov, polinomijalni i sigmoidni kernel, respektivno. Kao najbolji kernel se pokazao standardni

Slika 7: Pretraga za najbolji model sa Gausovim kernelom

Gausov kernel sa $\gamma^* = 0.0135$ i $C^* = 1.388$. Kao i ranije, prikazana je matrica

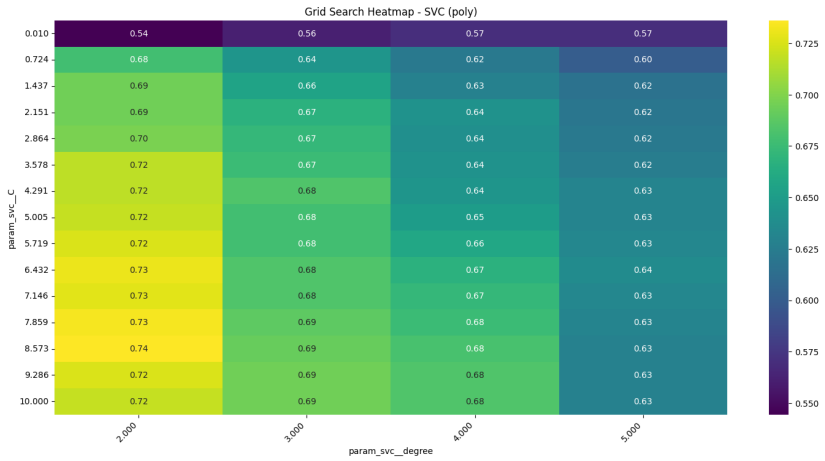

Slika 8: Pretraga za najbolji model sa polinomijalni kernelom

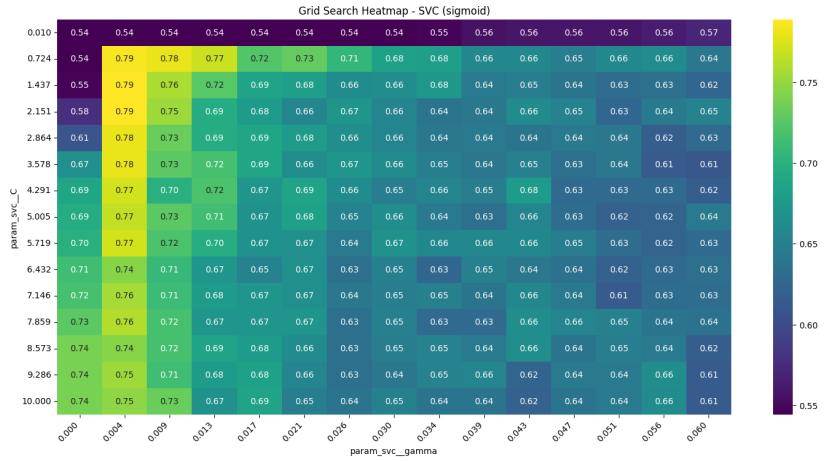

Slika 9: Pretraga za najbolji model sa sigmoidnim kernelom

konfuzije za trening skup (Slika 6) a rezultati optimalnog modela u Tabeli 5.

Tačnost	0.7667
Precision	0.7838
Recall	0.6905
F1	0.7342

Tabela 5: Rezultati testiranja optimalnog modela za $k = 130$

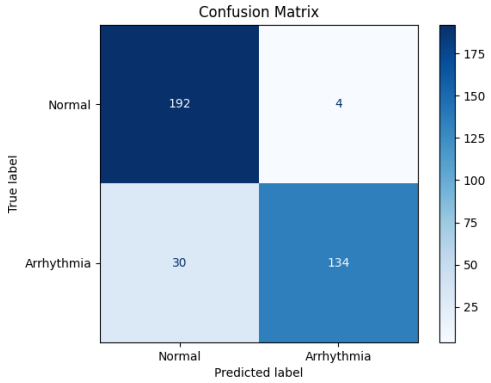

Slika 10: Matrica konfuzije za trening skup nakon obučavanja sa Gausovim kernelom i $\gamma^* = 0.0135$, $C^* = 1.388$

1.4 Ansambl metoda (XGB)

Kako se vidi iz test rezultata i matrica konfuzije, i logistička regresija i naivni Bayes-ov klasifikator imaju slično ponašanje. Posebno je interesantno što je odziv (eng. *recall*) ubedljivo najslabiji kod obe metode, dok je preciznost najviša metrika. Dakle, pretpostavka je da mešanje ovih metoda neće proizvesti značajne nove rezultate pa je kao ansambl odabran *Gradient Boosting* baziran na stablima odlučivanja (eng. *decision trees*). Postoji veliki broj hiper parametara koji utiču na obučavanje modela, počev od koraka učenja, maksimalne dubine svakog stabla, broja slabih učenika pa sve do onih koji se odnose na regularizaciju. Zbog velikog broja parametara i prirode XGB ansambala rađena je nasumična pretraga sa unakrsnom validacijom kao sredstvom poređenja modela. Dodatno, kako bi se rešio "problem" broja slabih učenika on je tkaođe modelovan kao hiperparametar koji se nasumično uzorkuje. Ovakav model se zatim koristi za testiranje na originalnom test skupu, Tabela 6 a vrednosti koje su pokazane kao najbolje performantne su: $k = 135$, stepen učenja $= 0.05$, maksimalna dubina pojedinačnog stabla $= 4$, broj slabih učenika $= 112$, $\alpha = 0.118$, $\lambda = 0.03$ i subsample $= 0.75$.

Kao što je i očekivano, postignuti su bolji rezultati nego u dosadašnjim, standardnim metodama klasifikacije. Može se reći da najveću razliku radi poboljšavanje odziva, koji je generalno zajednička najslabija tačka za sve modele do sada. Takođe, pretpostavlja se da zbog ogromnog prostora hiperparameara je moguće da se nađe još bolje rešenje međutim malo je verovatno da bi ono zaista napravilo značajnu razliku na nekom test skupu ili novim podacima. Zanimljivo je i da je broj prediktora sličan kao kod logističke regresije. Matrica konfuzije za trening skup je prikazana na Slici 11.

Tačnost	0.8000
Precision	0.8158
Recall	0.7381
F1	0.7750

Tabela 6: Rezultati testiranja najboljeg modela po nasumičnoj pretrazi

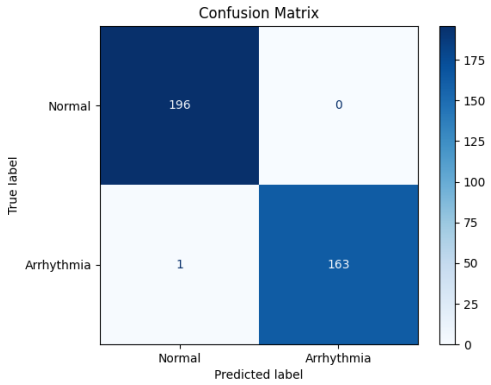

Slika 11: Matrica konfuzije za trening skup nakon obučavanja

1.5 Pregled Rezultata

Prvo će biti dat kratak pregled metoda i rezultata koji su dostupni na internetu za ovaj problem, nakon čegaa će bti prodiskutovani i rezultati ovog projekta. Na kraju će se razmotriti moguće nadogradnje i važni zaključci.

Kako je sam skup podataka dostupan na Kaggle-u postoji veliki broj priloženih rešenja. Jedno rešenje, zasnovano na XGB modelu, postiže preciznost od 69.23%. U sledećem kodu je analizirano više klasifikatora. Najbolje rezultate, u vidu preciznosti, su postigli Naivni Bayes(78.02%) i Nasumična šuma (74.73%). S obzirom da smo nasumičnom pretragom uspeli da dođemo do preciznosti veće od 80% na test skupu, zaključujemo da rezultati u prvom rešenju su dosta ispod mogućnosti XGB modela. Što se tiče drugog rešenja, dosta je temeljniji pregled

dat međutim u metrici AUC koja nama nije bila od interesa. Tu se Nasumična šuma pokazala kao najbolji klasifikator ali njena preciznost ukazuje na to da je XGB možda bolji izbor kada je reč o ansambl metodama. Rezultati preciznosti za Naivni Bayes su u potpunosti u skladu sa dobijenim rezultatima u ovom projektu, međutim nedostatak ostalih metrika ne garantuje da su performanse zaista jednake. U svakom slučaju, 80% verovatno predstavlja gornju granicu za preciznost tog modela.

Kada sagledamo sve modele, primećujemo da je ključna upravo selekcija osobina. Ovo je i očekivano zato što imamo nepogodan odnos broja osobina i podataka. Samim tim, modeli se lako mogu preobučiti šumom iz trening podataka. Ovo je toliko izraženo, da se u slučajevima unakrsne validacije dešava da podskupovi imaju osobine sa konstantnom vrednošću (0 varijanse) što govori u prilog razmeri ovog problema. Sama ANOVA-F statistika se pokazala izuzteno dobro u pronalaženju relevantih osobina gde je npr. za Naivni Bayes-ov klasifikator potrebno svega 67 od 250 osobina. Dakle, ukoliko neko želi da postigne maksimalne performanse na ovom skupu podataka od izuzetne je važnosti da se sprovede detaljna analiza osobina i zaista ispita njihov značaj. Uvođenje novih podataka i proširavanje skupa bi isto dovelo do lakše selekcije osobina i smanjenja varijanse modela. Još jedna stvar koju treba uzeti u razmatranje je činjenica da detekcija oba slučaja nije od jednake važnosti. Daleko je opasnije pogrešno klasifikovati aritmiju nego normalan otkucaj. Nikad ne možemo biti previše oprezni! Samim tim, u praktičnoj primeni nekog modela bilo bi od interesa ispitati različite politike donošenja odluka, kao i prikazati ROC krive radi stivanja intuicije. Otežavanje primeraka aritmija prilikom treninga bi verovatno bilo korisno posebno zato što se na svim matricama konfuzije vidi da se aritmije češće pogrešno klasifikuju.

2 Dodatak

Osnovni parametri (1–15)

Br.	**Opis**	**Tip**
1	Age (godine)	linear
2	Sex (0 = male; 1 = female)	nominal
3	Height (cm)	linear
4	Weight (kg)	linear
5	QRS duration (prosek, msec)	linear
6	P-R interval (msec)	linear
7	Q-T interval (msec)	linear
8	T interval (msec)	linear
9	P interval (msec)	linear
10–14	Vector angles (front plane): QRS (10), T (11), P (12), QRST (13), J (14)	linear
15	Heart rate (otkucaja/min)	linear

Širina talasa po kanalima (DI, DII, DIII, AVR, AVL, AVF, V1–V6)

Za svaki kanal (12 kanala) ponavlja se ista struktura:

Br.	Opis	Tip
16, 28, 40, 52, 64, 76, 88, 100, 112, 124, 136, 148	Q wave	linear
17, 29, 41, 53, 65, 77, 89, 101, 113, 125, 137, 149	R wave	linear
18, 30, 42, 54, 66, 78, 90, 102, 114, 126, 138, 150	S wave	linear
19, 31, 43, 55, 67, 79, 91, 103, 115, 127, 139, 151	R' wave	linear
20, 32, 44, 56, 68, 80, 92, 104, 116, 128, 140, 152	S' wave	linear
21, 33, 45, 57, 69, 81, 93, 105, 117, 129, 141, 153	Number of intrinsic deflections	linear
22, 34, 46, 58, 70, 82, 94, 106, 118, 130, 142, 154	Existence of ragged R wave	nominal
23, 35, 47, 59, 71, 83, 95, 107, 119, 131, 143, 155	Existence of diphasic derivation of R wave	nominal
24, 36, 48, 60, 72, 84, 96, 108, 120, 132, 144, 156	Existence of ragged P wave	nominal
25, 37, 49, 61, 73, 85, 97, 109, 121, 133, 145, 157	Existence of diphasic derivation of P wave	nominal
26, 38, 50, 62, 74, 86, 98, 110, 122, 134, 146, 158	Existence of ragged T wave	nominal
27, 39, 51, 63, 75, 87, 99, 111, 123, 135, 147, 159	Existence of diphasic derivation of T wave	nominal

Napomena: Brojevi atributa su raspoređeni po kanalima: DI (16–27), DII (28–39), DIII (40–51), AVR (52–63), AVL (64–75), AVF (76–87), V1 (88–99), V2 (100–111), V3 (112–123), V4 (124–135), V5 (136–147), V6 (148–159).

Amplitude i površine talasa po kanalima

Za svaki kanal (12 kanala) ponavlja se ista struktura:

Br.	Opis	Tip
160, 170, 180, 190, 200, 210, 220, 230, 240, 250, 260, 270	JJ wave (0.1 mV)	linear
161, 171, 181, 191, 201, 211, 221, 231, 241, 251, 261, 271	Q wave (0.1 mV)	linear
162, 172, 182, 192, 202, 212, 222, 232, 242, 252, 262, 272	R wave (0.1 mV)	linear
163, 173, 183, 193, 203, 213, 223, 233, 243, 253, 263, 273	S wave (0.1 mV)	linear
164, 174, 184, 194, 204, 214, 224, 234, 244, 254, 264, 274	R' wave (0.1 mV)	linear
165, 175, 185, 195, 205, 215, 225, 235, 245, 255, 265, 275	S' wave (0.1 mV)	linear
166, 176, 186, 196, 206, 216, 226, 236, 246, 256, 266, 276	P wave (0.1 mV)	linear
167, 177, 187, 197, 207, 217, 227, 237, 247, 257, 267, 277	T wave (0.1 mV)	linear
168, 178, 188, 198, 208, 218, 228, 238, 248, 258, 268, 278	QRSA (površina/10)	linear
169, 179, 189, 199, 209, 219, 229, 239, 249, 259, 269, 279	QRSTA	linear

Napomena: Brojevi atributa su raspoređeni po kanalima: DI (160–169), DII (170–179), DIII (180–189), AVR (190–199), AVL (200–209), AVF (210–219), V1 (220–229), V2 (230–239), V3 (240–249), V4 (250–259), V5 (260–269), V6 (270–279).

Rezime atributa

Ukupan broj atributa: 279

Kategorija	**Broj atributa**
Osnovni parametri (1–15)	15
Širine talasa (12 kanala $\times$ 12 atributa)	144
Amplitude i površine (12 kanala $\times$ 10 atributa)	120
Ukupno	**279**